BCMID — Breast Cancer Multimodal Intelligent Diagnosis

Rapport technique de Deep Learning • Version française • Projet académique ESPRIT • 2026–2027

Résumé et périmètre

BCMID est un prototype de système d’aide à l’interprétation d’examens mammaires associant mammographie, échographie et éléments cliniques. L’architecture articule un modèle de vision ResNet-18, une explicabilité Grad-CAM, une recherche documentaire RAG, une synthèse par LLM et un contrôle de sécurité avant production du compte rendu. L’objectif est de faciliter la revue par un professionnel, et non de poser un diagnostic autonome.

Objectifs techniques

(1) Contrôler la qualité et la traçabilité des données ; (2) comparer les modalités visuelles et leur fusion ; (3) produire des indications interprétables et reliées aux preuves récupérées ; (4) limiter les sorties non étayées du LLM ; (5) fournir un rapport à relire obligatoirement.

Méthode de vérification

Le présent document reprend le rapport initial, mais le confronte aux modules Python, aux tests, aux index vectoriels et aux artefacts inclus dans le ZIP. Une distinction est conservée entre résultats rapportés, code présent et exécution effectivement attestée. La classification BI-RADS issue d’un score numérique dans le projet est une heuristique non validée cliniquement.

Orientation du rapport

La table des matières détaillée figure à la page suivante. Le schéma global de l’architecture est reproduit en Annexe A, en grand format.

Table des matières

BCMID — Breast Cancer Multimodal Intelligent Diagnosis | Année universitaire 2026–2027

Section	Intitulé	Page
—	Résumé et périmètre	1
1	Architecture agentique et justification	3
2	Choix des outils et justification	4
3	Choix du modèle de langage (LLM)	5
4	Approche RAG clinique	6
5	Évaluation du système	7
6	Sécurité, confidentialité et réglementation	8
—	Conclusion	8
Annexe A	Architecture globale multimodale avec XAI et n8n	9

Présentation de l’architecture

La figure de l’Annexe A reprend l’architecture fournie : couche d’entrée, contrôle qualité, analyse multimodale (mammographie et échographie), agent RAG, agent de raisonnement, contrôle Safety et génération du rapport. Le workflow n8n assure l’orchestration. Les technologies et alternatives figurant dans ce schéma sont illustratives ; la description des composants effectivement identifiés dans le dépôt est précisée dans les sections suivantes.

Note de lecture

Les métriques reproduites de l’ancien rapport sont distinguées des résultats directement reproductibles à partir des artefacts fournis. BCMID reste un prototype académique non validé pour une utilisation clinique.

1. Architecture agentique et justification

La chaîne est décomposée en sept blocs spécialisés afin de séparer les traitements statistiques, l'accès aux connaissances médicales, la génération textuelle et les vérifications déterministes. Cette séparation améliore la modularité, la capacité à auditer chaque résultat et le traitement des erreurs propres aux modalités.

Bloc	Responsabilité	Sortie principale
1. Ingestion	Contrôle et identification des fichiers	Dossier prêt à traiter
2. Data Quality	Anonymisation, intégrité, prétraitement	Images nettoyées / manifeste
3. Vision	ResNet-18 et explicabilité	Scores, incertitude, Grad-CAM
4. Clinical RAG	Recherche de directives et cas	Fragments sourcés
5. Reasoning	Synthèse des signaux et preuves	Proposition de rapport
6. Safety	Contrôles lexicaux, numériques et citations	Acceptation ou révision
7. Reporting	Production de sorties lisibles	Rapport PDF / interface HTML

Chaîne de traitement

Mammographie + échographie + texte clinique → ingestion et qualité → vision et RAG → raisonnement assisté par LLM → audit de sécurité → rapport pour validation humaine. Le dépôt contient aussi un workflow n8n destiné au routage événementiel. L'architecture relève d'un pipeline multi-composants orchestré : chaque bloc est spécialisé, sans supposer que tous prennent des décisions autonomes.

Pourquoi cette architecture ?

Les images et les textes appellent des traitements différents. Une analyse séquentielle et vérifiable est préférable à un unique modèle génératif opaque dans un domaine à forts enjeux. La boucle Safety → Reasoning est bornée à deux tentatives de correction ; un échec doit conduire à une revue manuelle, pas à une conclusion clinique forcée.

2. Choix des outils et justification

Composant	Choix	Justification / compromis
Vision	PyTorch, torchvision, ResNet-18	Architecture CNN relativement légère ; transfert et Grad-CAM possibles ; dépend de poids entraînés accessibles.
Qualité image	OpenCV, Pillow, OCR selon traitement	Normalisation, extraction, réduction des artefacts ; transformations à valider sur les lésions.
RAG	FAISS + sentence-transformers	Recherche locale rapide et reproductible ; nécessite indexation et contrôle de provenance.
API	FastAPI + Pydantic	Endpoints typés et validation des entrées ; sécurité réseau à configurer.
Synthèse	Transformers / Qwen2.5-3B-Instruct	Inférence locale envisageable ; fonctionnement alternatif si modèle absent.
Rapports	ReportLab et HTML	Production structurée des comptes rendus.
Orchestration	n8n	Chaînage de webhooks, conditions et acheminement ; pas une preuve d'intégration hospitalière validée.
Tests	pytest	Contrôles unitaires, de cohérence et de non-régression.

Trade-offs principaux

ResNet-18 limite la complexité par rapport à de gros modèles mais nécessite une calibration médicale spécifique. FAISS évite une dépendance obligatoire au cloud, au prix d'une gestion locale des index et droits. n8n rend les scénarios lisibles, mais ajoute un service à protéger. Le traitement local réduit certains transferts de données sans garantir, à lui seul, la conformité réglementaire.

3. Choix du modèle de langage

Qwen2.5-3B-Instruct : rôle et intégration

Le code de src/reasoning/reasoning_agent.py cible Qwen/Qwen2.5-3B-Instruct. Le modèle a pour mission de transformer des sorties visuelles structurées et des passages RAG en texte clinique traçable. Ce n'est pas le classifieur d'images et il ne remplace pas l'examen d'un radiologue.

Les arguments de choix sont la taille modérée (environ 3 milliards de paramètres), une exécution locale possible sur matériel adapté, le suivi d'instructions et la capacité à produire du texte structuré. Une quantification pourrait réduire les besoins mémoire, mais son effet sur la qualité doit être testé. Le décodage sans échantillonnage (do_sample=False dans le code) limite la variabilité, sans garantir à lui seul l'exactitude.

Important : inférence réelle vs repli

Le module tente de charger les poids localement via Transformers (local_files_only=True). Si le modèle n'est pas accessible, une fonction mock_reasoning_agent_llm applique des règles et indique reasoning_mode=rule_based_fallback et simulation_mode=True. Les sorties obtenues dans ce cas ne peuvent pas servir à démontrer les performances de Qwen.

Maîtrise des hallucinations

Le prompt inclut les informations cliniques disponibles et les extraits récupérés ; le résultat doit conserver les citations, les limites et l'obligation de validation humaine. Le Safety Agent compare ensuite la proposition aux sources et aux sorties de vision, en demandant une révision si les contrôles échouent.

4. Approche RAG clinique

Pourquoi utiliser le RAG ?

Les directives et les éléments documentaires peuvent être mis à jour sans réentraîner le LLM. Les fragments récupérés donnent une base explicite à la synthèse et facilitent la traçabilité. Le RAG réduit certaines hallucinations, sans les éliminer.

Index, encodage et recherche

Le dépôt contient acr_guidelines_index.faiss et rag_index.faiss, ainsi que les corpus associés. La documentation présente 11 règles de référence et 317 fragments de cas historiques. L'encodeur choisi est BAAI/bge-small-en-v1.5 (384 dimensions). Une requête est vectorisée, comparée aux passages, puis un petit ensemble de résultats (top-k, généralement 4) est transmis à l'agent de raisonnement avec provenance.

Le code ikbelwork/clinical_rag_enhancer.py permet d'exclure un identifiant patient (exclude_pseudo_id) lors de la récupération ; ce contrôle ne constitue pas, à lui seul, une preuve d'absence de fuite entre plis. Le comportement prévoit également un mécanisme alternatif lorsque le modèle d'embeddings n'est pas disponible. Il faut évaluer la précision des passages et distinguer les textes de référence des cas historiques.

Évaluation RAG recommandée

Constituer des requêtes annotées par un professionnel, mesurer Recall@4 / précision des citations, pertinence des passages et taux de réponses non étayées. Documenter les versions et licences des référentiels ; éviter de qualifier l'index d'« officiel » sans vérification des droits et de la provenance.

5. Évaluation et résultats

Le rapport précédent présente les performances suivantes sur une cohorte fusion mentionnée de 323 patientes. Ces valeurs sont reprises comme résultats rapportés ; les protocoles d'entraînement, poids et prédictions nécessaires à une reproduction indépendante ne sont pas tous présents dans l'archive.

Configuration	AUC ROC rapportée	Sensibilité rapportée
Mammographie ResNet-18	0,7917	76,2 %
Échographie ResNet-18	0,6743	68,4 %
Fusion multimodale	0,8198	83,1 %

Validation et explicabilité

Le rapport initial mentionne 387 cartes Grad-CAM et 87,4 % d'énergie d'activation dans la région mammaire. Il s'agit d'un indicateur de localisation, pas d'une preuve de raisonnement clinique correct. Les modules tests/ vérifient notamment anonymisation, intégrité, modalités, partitions et contrôle de sécurité. L'ancien rapport consigne 61 tests réussis ; ce document n'assimile pas ce résultat à une nouvelle exécution indépendante.

Limites de la démonstration actuelle

Aucun fichier de poids ResNet-18 (*.pth/*.pt) n'a été repéré dans le ZIP. src/vision/vision_agent.py prévoit explicitement des scores simulés en l'absence de checkpoint. Il faut séparer les résultats de benchmark historiques de la démonstration locale en mode simulation. Avant toute conclusion clinique : validation externe, intervalles de confiance, sensibilité à seuil fixé, analyses par densité mammaire et audits des erreurs.

6. Sécurité, confidentialité et conformité

Protection des données et intégrité

La chaîne documente pseudonymisation des identifiants, nettoyage des comptes rendus, empreintes SHA-256 et séparation patient entre partitions. Cependant, un pseudonyme haché reste une donnée potentiellement ré-identifiable : minimisation, contrôle d'accès, journalisation, chiffrement, gestion des secrets et politiques de conservation restent nécessaires.

Sûreté des sorties et contrôle humain

Le Safety Agent vérifie l'existence des citations, les contradictions textuelles, les nombres attribués à la vision et les mentions d'incertitude. Une sortie incohérente doit être marquée pour revue médicale, sans recommandation automatisée définitive. Les seuils probabilistes employés pour transformer un risque en catégories BI-RADS sont heuristiques ; ils ne sont pas une équivalence médicale validée.

Menaces à tester

Ajouter des scénarios de prompt injection dans les notes et les documents RAG, entrées d'images malformées, fuite inter-patients, empoisonnement de corpus, accès non autorisés aux rapports, exposition des webhooks n8n et dérive des modèles. Prévoir authentification, autorisation par rôle, vérification des entrées, gestion des versions et plan de réponse aux incidents.

Statut réglementaire

BCMID doit être présenté comme un prototype académique de recherche non validé pour l'usage clinique. La qualification éventuelle comme dispositif médical et sa classe au titre du règlement UE 2017/745 exigent une analyse formelle de l'usage prévu et du cadre juridique. La présence de mécanismes de sécurité n'équivaut pas à une certification RGPD, HIPAA ou MDR.

Conclusion

Le point fort de BCMID est une architecture traçable combinant vision multimodale, RAG, synthèse et audit. La prochaine étape prioritaire est de réunir les poids, reproduire les métriques sur données séparées, tester la génération LLM réelle et faire examiner les rapports par des radiologues avant tout usage au-delà du cadre académique.

Sources : ancien rapport BCMID v3.0 fourni ; code et artefacts de l'archive GitHub fournie (README.md, src/vision/vision_agent.py, src/reasoning/reasoning_agent.py, ikbelwork/clinical_rag_enhancer.py, ikbelwork/run_orchestrator.py, tests/, bcmid_work/).

ANNEXE A — Architecture globale du projet BCMID

Architecture fournie par l'équipe projet / Project team architecture

