Dossier Technique & Clinique : Data & Quality Agent (Blocs 1 & 2)

Auteur : Laboratoire Data Quality & Ingestion | **Dataset :** BCMID (Breast Cancer Multimodal Integrated Dataset)

Résumé Exécutif : *Le notebook data-quality-clean.ipynb constitue le socle fondamental (Blocs 1 et 2) de tout le pipeline décisionnel. Face à un jeu de données multimodal réel hétérogène (2001 clichés d'imagerie, 321 rapports PDF non structurés), l'Agent Qualité opère une refonte complète : audit d'intégrité, normalisation des polarités inversées, suppression des bordures parasites, masquage OCR des métadonnées incrustées, anonymisation réglementaire des rapports textuels, neutralisation des raccourcis d'apprentissage (shortcut learning), et découpage étanche en 5 plis par groupe patient longitudinal (GroupKFold). Ce document synthétise les méthodes, les statistiques clés et les artefacts de sortie produits.*

1. Profiling & Inventaire Initial du Dataset BCMID (Étape 0)

L'exploration exhaustive du stockage BCMID (12.11 GB) a permis d'établir l'inventaire strict des fichiers bruts avant toute opération de nettoyage :

Type d'Artefact	Extension	Nombre de Fichiers	Volume Disque	Usage dans le Pipeline
Clichés d'Imagerie	.png	**2 001**	~12.0 GB	Mammographies (CC, MLO) et Échographies (US)
Comptes-Rendus Médicaux	.pdf	**321**	~110 MB	Rapports radiologiques d'examens bilingues
Table d'Annotations	.tsv	**1**	8.7 KB	Vérité terrain (BI-RADS, Pathologie, Binaire)
TOTAL GLOBAL	Tous formats	**2 323**	**12.11 GB**	332 patientes uniques

2. Distribution Pathologique & Gestion Rigoureuse des 5 Cas BI-RADS 0 (Étape 1)

La table d'annotation BCMID_annotations.tsv indexe 332 patientes réparties en 3 classes pathologiques principales, avec un sous-groupe singulier exigeant un traitement clinique dédié :

Classe Pathologique	Label Binaire	Score BI-RADS Typique	Patientes	Traitement en Machine Learning
Bénin (Benign)	Negative	BI-RADS 2 ou 3	**214 (64.5%)**	Supervisé (Classe 1)
Malin (Malignant)	Positive	BI-RADS 4 ou 5	**63 (19.0%)**	Supervisé (Classe 2 - Priorité oncologique)
Normal	Negative	BI-RADS 1	**50 (15.1%)**	Supervisé (Classe 0)
BI-RADS 0 (Incomplet)	Non étiqueté (NaN)	BI-RADS 0	**5 (1.5%)**	**Conservées !** Flag eval_unlabeled=True

Traitement des 5 Patientes BI-RADS 0 (3761y16, 7281y18, 1946y18, 1265y07, 00639y20) :
En milieu médical, BI-RADS 0 signifie 'Évaluation incomplète - Nécessite des clichés complémentaires ou une échographie ciblée'. ***Décision d'ingénierie :*** *Les patientes ne sont* ***PAS supprimées*** *(ce qui détruirait des données réelles précieuses). Elles sont intégrées avec l'attribut eval_unlabeled=True. Elles sont exclues de la fonction de perte supervisée (Cross-Entropy) lors de l'entraînement, mais conservées pour les démonstrations de l'agent RAG et les audits de sécurité clinique.*

3. Gestion du Biais Longitudinal & Découpage Étanche GroupKFold (Étapes 3 & 7)

Certaines patientes possèdent des examens répétés sur plusieurs années (ex. dépistage initial en 2011, puis suivi en 2013). Si l'examen de 2011 se trouvait dans le train et celui de 2013 dans le test, le réseau apprendrait à reconnaître la texture mammaire individuelle (Data Leakage majeur).

• **Création de l'identifiant patient regroupé (group_pseudo) :** Regroupement systématique de tous les examens appartenant à la même patiente physique.
• **Découpage par GroupKFold(n_splits=5) :** Garantie mathématique stricte qu'une patiente et tous ses clichés (quelles que soient les années) n'apparaissent que dans **un seul pli**.
• **Équilibre inter-plis :** Répartition homogène des classes pathologiques (environ 40 Bénins, 13 Malins et 10 Normaux par pli).

4. Diagnostic d'Image & Normalisation Visuelle Avancée (Étape 5)

Les 2001 images présentaient des variations extrêmes d'acquisition selon les centres et constructeurs. Quatre transformations correctives standardisées ont été déployées :

Anomalie Détectée	Description Technique	Correctif Appliqué dans le Lab
Inversion de Polarité	Certaines mammographies sont acquises avec fond blanc (255) et parenchyme sombre, à l'inverse du standard radiologique.	Calcul de la moyenne des 4 coins d'image. Si fond > 127 ➡■ Inversion img = 255 - img. 100% des images remises sur fond noir.
Bordures & Artéfacts	Bandes noires, collimateurs optiques ou zones blanches parasites sur les bordures externes.	Seuillage Otsu + détection de la plus grande composante connexe ➡■ Rognage automatique centré sur le sein (Bounding Box).
Hétérogénéité de Taille	Mammographies allant de 800 à 4000 px ; Échographies de résolutions hétérogènes.	Redimensionnement bilinéaire avec maintien du ratio d'aspect (Letterboxing) : • **Mammographie :** 1280 × 1024 px • **Échographie :** 360 × 512 px
Texte Incrusté (US)	Les constructeurs d'échographes incrustent le nom de la clinique, l'âge et les paramètres sur l'image.	Détection OCR par **EasyOCR** ➡■ Masquage par inpainting noir (valeur 0) pour empêcher le réseau de lire des métadonnées.

5. Neutralisation des Biais d'Acquisition (Shortcut Learning) (Étape 5C & 5E)

Une découverte critique du diagnostic qualité a mis en évidence deux catégories d'appareils mammographiques :

• **Source Standard (Haute Définition) :** Capteurs numériques récents, excellente résolution spatiale et contraste élevé.
• **Source Non Standard (Basse Résolution / Numériseur secondaire) :** Images plus bruitées, contraste réduit.

Risque de Raccourci (Shortcut Learning) : Si une source d'appareil était corrélée avec la gravité des cas (ex. machine d'oncologie spécialisée), le réseau de neurones prédirait le cancer en se basant sur le *bruit du capteur* plutôt que sur les *anomalies tissulaires*.
Solutions apportées :
1. Création de la variable standard_device (True/False) pour tracer chaque cliché.
2. Définition du sous-ensemble **eval_main (154 patientes unilatérales sur source standard)** pour tester le modèle en conditions d'évaluation pures et non biaisées.
3. Injection de sondes de signature (probe features) pour s'assurer que la décision finale repose sur la biologie et non l'appareil.

6. Anonymisation Stricte des Rapports PDF (Étape 6)

Les 321 rapports médicaux PDF ont fait l'objet d'une extraction et d'un caviardage complet conforme aux normes HIPAA/RGPD :

• **Suppression des Identifiants Directs :** Noms de patientes, numéros de dossier médical, noms des médecins référents et des radiologues remplacés par [ID], [DOCTOR].
• **Masquage Temporel :** Dates exactes remplacées par [DATE].
• **Génération de deux versions par rapport :**
1. text_clean : Rapport complet anonymisé sans données d'identification.
2. text_blind : Rapport sans aucune conclusion chiffrée BI-RADS ni mention directe de cancer, servant de base saine pour le RAG.

7. Inventaire des Fichiers Clés Produits dans /kaggle/working

L'exécution complète de data-quality-clean.ipynb a produit les artefacts de référence réutilisés par les notebooks suivants :

Artefact Généré	Format & Taille	Rôle dans le Pipeline Aval
dataset_final.csv	CSV / ~35 KB	**Fichier maître indispensable** : Indexe les 332 patientes, leurs identifiants anonymes (pseudo_id), leur groupe longitudinal, leurs labels, leurs plis 0-4 et les flags eval_main et eval_unlabeled.
images_anon.csv	CSV / ~240 KB	Table de correspondance des 1 974 clichés d'imagerie nettoyés, avec vue radiologique (CC/MLO), modalité (Mammo/US) et chemin physique.
reports_anon/	Dossier / 321 fichiers JSON	Rapports médicaux anonymisés prêts pour l'ingestion par le modèle d'embedding du Clinical RAG (Bloc 4).
processed/	Dossier PNG / ~4 GB	Dossier contenant les sous-dossiers mammo/ (951 images) et us/ (1023 images) normalisées et prêtes pour l'entraînement PyTorch.
quality_report.json	JSON / ~10 KB	Rapport d'audit qualité exhaustif résumant toutes les métriques de conformité pour traçabilité réglementaire.

8. Bilan Qualité & Conformité Médicale

Le laboratoire Data & Quality garantit la solidité scientifique et éthique de l'ensemble du projet :

Exigence du Projet	Statut	Résultat Obtenu
Intégrité des Métadonnées TSV	**100% CONFORME**	332 patientes vérifiées, aucune ligne corrompue
Préservation des cas BI-RADS 0	**100% CONFORME**	5 cas conservés avec flag eval_unlabeled
Absence de fuite patient inter-plis	**100% CONFORME**	GroupKFold strict sur group_pseudo
Normalisation des polarités images	**100% CONFORME**	100% des fonds blancs inversés en fond noir standard
Suppression métadonnées incrustées	**100% CONFORME**	EasyOCR + inpainting noir sur échographies
Anonymisation des rapports cliniques	**100% CONFORME**	321 rapports caviardés selon normes médicales

Conclusion : Grâce à ce travail minutieux de préparation, le Vision Agent (Bloc 3) et le RAG Agent (Blocs 4-7) ont pu s'entraîner et raisonner sur des données rigoureusement étanches, dé-bruitées et standardisées, garantissant des performances prédictives fiables et transposables en pratique clinique.