Dossier Technique & Clinique : Agent RAG, Raisonnement LLM & Sécurité (Blocs 4 à 7)

Auteur : Travaux dirigés & Laboratoire RAG Agent | **Projet :** Diagnostic du Cancer du Sein Assisté par IA

Résumé Exécutif : *Le notebook rag-agent.ipynb implémente les Blocs 4, 5, 6 et 7 de l'architecture cible du projet. Il assure l'intégration synergique entre les représentations visuelles issues du modèle de Deep Learning (Vision Agent - ResNet-18 multimodal), l'indexation vectorielle dense de rapports cliniques et de guides officiels ACR BI-RADS via embeddings BGE et FAISS (Clinical RAG), la synthèse médicale par un modèle de langage (LLM Qwen2.5-3B-Instruct), et un agent d'audit de sécurité médical avec boucle de rétroaction active. Ce document détaille chaque étape technique, les choix d'ingénierie, les métriques obtenues et la structure des rapports finaux générés.*

1. Positionnement dans l'Architecture Globale du Projet

L'architecture de référence du projet ('Multimodal Medical AI Automation System with XAI') est structurée en 7 blocs séquentiels. Le présent laboratoire couvre l'intégralité de la chaîne décisionnelle avale :

Bloc	Dénomination	Rôle Technique & Médical	Statut Lab RAG
Bloc 1 & 2	Input & Data Quality	Nettoyage, anonymisation, 5 plis groupés par patiente (332 cas)	Validé (Notebook 1)
Bloc 3	Multimodal Vision Agent + XAI	ResNet-18 (Mammo + Écho), calibration BI-RADS, Grad-CAM (387 cartes)	Validé (Notebook 2)
Bloc 4	Clinical RAG Agent	Recherche vectorielle dense : guides ACR BI-RADS + rapports historiques	**Au cœur du Lab RAG**
Bloc 5	Medical Reasoning Agent	Synthèse multimodale par LLM (Qwen2.5-3B-Instruct) sous prompt contraint	**Au cœur du Lab RAG**
Bloc 6	Quality & Safety Agent	Détection hallucinations, vérification de l'ancrage et boucle de révision	**Au cœur du Lab RAG**
Bloc 7	Final Structured Output	Production de comptes-rendus standardisés (JSON structuré + HTML)	**Au cœur du Lab RAG**

2. Prétraitement des Rapports & Prévention des Fuites d'Information (R0)

L'évaluation rigoureuse d'un agent RAG médical impose qu'aucune information de vérité terrain (ground truth) ne soit accessible au modèle de langage lors de la génération. Trois niveaux de sécurisation ont été appliqués :

• **Création de text_blind :** Suppression systématique et vérifiée de toute mention explicite de score BI-RADS (ex. BI-RADS 4, ACR 2). Vérification par expression régulière : 0 chiffre BI-RADS subsistant dans les textes aveugles.
• **Purge des antécédents oncologiques directs de l'en-tête (R0f) :** Les mentions de traitements adjuvants (mastectomy, lumpectomy, chemotherapy, pathologically proved cancer) ont été caviardées par la balise [CLINICAL HISTORY REMOVED] pour 15 patientes afin d'éviter tout raccourci diagnostique trivial.
• **Dé-doublonnage sémantique :** Élimination des rapports dupliqués ou de moins de 30 mots, aboutissant à une cohorte exploitable de **317 rapports cliniques propres**.

3. Moteur Vectoriel Clinical RAG Dense (BGE + FAISS) (R1 & R2)

Le système repose sur un double index vectoriel dense assurant la contextualisation clinique de chaque dossier :

Index 1 : Base Clinique ACR BI-RADS Atlas	Index 2 : Cas Patients Historiques BCMID
• **Source :** Recommandations officielles de l'American College of Radiology (ACR). • **Contenu :** 11 règles canoniques couvrant les catégories BI-RADS 0 à 6, les patrons de densité ACR A-D, et le lexique échographique (forme, contours, échogénicité). • **Index :** acr_guidelines_index.faiss. • **Objectif :** Fournir au LLM la justification normative et la conduite à tenir officielle (ex. biopsie au trocart vs surveillance 6 mois).	• **Source :** Rapports textuels anonymisés du dataset BCMID. • **Découpage :** 317 chunks textuels nettoyés. • **Index :** rag_index.faiss. • **Objectif :** Raisonnement par analogie de cas (Case-Based Reasoning). Identification de patientes présentant des anomalies sémiologiques similaires. • **Isolation stricte :** Les cas du même pli ou de la patiente test sont exclus pour éviter toute contamination.

Modèle d'embedding : BAAI/bge-small-en-v1.5 (dimension 384). Recherche par similarité cosinus via IndexFlatIP après normalisation L2 des vecteurs, garantissant une latence d'inférence < 5 ms par requête.

4. Conditionnement Multimodal & Ingestion des Scores Vision + XAI (R3)

Pour chaque patiente du pli d'évaluation (pli 0, 64 patientes), un dossier multimodal unifié est assemblé. L'agent de raisonnement est testé selon 3 conditions expérimentales contrôlées :

Condition	Données Fournies dans le Prompt	Nombre de Cas	Longueur Médiane
image	Scores de probabilité du ResNet-18 (Mammo + US) + Résumé textuel des zones Grad-CAM	64	245 mots
texte	Rapport clinique nettoyé + Preuves RAG E1/E2 issues d'autres patientes (si rapport disponible)	60	442 mots
les_deux	Fusion intégrale : Scores vision + Zones chaudes Grad-CAM + Rapport patiente + Preuves RAG E1/E2	64	486 mots

Intégration de l'Explicabilité XAI (Grad-CAM) dans le Prompt :

Plutôt que de fournir des pixels bruts, les 387 cartes de chaleur Grad-CAM générées par le Vision Agent sont traduites en descriptions spatiales sémantiques (ex. *'milieu de l'image, côté opposé à la paroi'*, *'haut de l'image, côté paroi thoracique'*) et injectées sous la clé HEATMAP SUMMARY. Le LLM sait ainsi précisément quelles régions ont motivé la prédiction du réseau convolutif.

5. Modèle de Raisonnement Médical (Qwen2.5-3B-Instruct) (R4a)

Le modèle de langage sélectionné est **Qwen2.5-3B-Instruct**, exécuté en précision float16 sur GPU Tesla T4 (occupation VRAM : 3.1 Go). Ce modèle a été choisi pour son excellent respect des schémas JSON stricts et sa capacité de raisonnement médical concis.

Schéma JSON Imposé (Bloc 5 & 7) :

```
{
  "patient_summary": "Synthèse du profil patient, de la condition et du type de matériel (Standard/Non-standard)",
  "predicted_birads": "Catégorie BI-RADS attribuée (1, 2, 3, 4A, 4B, 5)",
  "confidence": "Score de confiance calibré (0.0 à 1.0)",
  "interpretation": "Raisonnement multimodal synthétique articulant vision et texte",
  "supporting_evidence": "Citations obligatoires des règles ACR [G1, G2] et cas similaires [E1, E2]",
  "visual_explanations": "Localisation des zones d'attention saillantes (Mammographie et Échographie)",
  "recommendations": "Conduite à tenir clinique concrète (Biopsie, surveillance 6 mois, dépistage annuel)",
  "limitations": "Limites de l'IA, fiabilité matériel, incertitude du modèle",
  "human_review_required": true
}
```

6. Agent de Sécurité Clinique & Boucle de Rétroaction (Bloc 6)

Dans un environnement médical automatisé, l'IA ne peut être déployée sans garde-fous stricts. Le Quality & Safety Agent applique 4 catégories de contrôles déterministes avant toute validation :

Règle de Sécurité	Mécanisme d'Audit Déterministe	Sanction en cas d'Échec
Anti-Hallucination Médicale	Vérification que tout terme lésionnel (*mass, nodule, cyst, calcification, thickening*) cité par le LLM est présent mot pour mot dans le rapport d'origine ou les preuves.	Erreur de groundedness ➡■ Révision demandée au LLM.

Cohérence Numérique Stricte	Contrôle que toute valeur chiffrée citée (pourcentage de malignité, entropie) correspond exactement aux probabilités calculées par le ResNet-18 (tolérance ±0.6%).	Rejet du résumé ➡■ Régénération sans invention de chiffre.
Divulgation de l'Incertitude	Si l'entropie d'incertitude du modèle est ≥ 0.50, l'avertissement d'incertitude élevée doit obligatoirement figurer dans les limitations.	Omission de sécurité ➡■ Injection de la réserve clinique requise.
Avertissement Matériel	Pour les patientes acquises sur appareil non standard (faible résolution), une mention explicite de moindre fiabilité doit être signalée.	Omission de sécurité ➡■ Blocage jusqu'à mention explicite.

7. Résultat Concret : Exemple de Rapport Médical Structuré (Bloc 7)

Voici un compte-rendu réel extrait du fichier final_medical_reports_sample.json généré par la dernière cellule du notebook pour la patiente **P0159** :

Patient : P0159 | **Condition :** Multimodale (les_deux) | **Matériel :** Non-standard (reduced resolution)
Prédiction Globale : BI-RADS 4A (Suspicion faible à modérée de malignité) | **Confiance :** 78.0%
Synthèse & Interprétation Vision (ResNet-18) :
"Mammography model: normal 0.36, benign 0.51, malignant 0.14 (uncertainty entropy 0.90, high). Ultrasound model malignant probability 0.62. The two modality scores point in different directions. Non-standard acquisition device: scores are less reliable."

Explications Visuelles XAI (Grad-CAM) :
• Mammographie : *Attention portée sur la densité parenchymateuse et l'asymétrie focale.*
• Échographie : *Attention portée sur la zone tissulaire hypoéchogène.*

Preuves Cliniques Analogues Retrouvées par RAG :
• **[E1] (Similarité 0.942) :** *"Both breasts are of scattered fibroglandular pattern (ACR b)... global asymmetry with markedly diminished size & upper central diffuse s"*
• **[E2] (Similarité 0.938) :** *"Both breasts are of scattered fibroglandular pattern (ACR b)... mild skin thickening with surgical clips"*

Recommandations Cliniques Officielles ACR :
1. Image-guided core needle biopsy (CNB) recommended.
2. Multidisciplinary breast tumor board review.

Audit de Sécurité Qualité :
• Groundedness vérifié : **OUI** | Hallucinations détectées : **NON** | Cohérence BI-RADS : **OUI** | **Validation humaine radiologue requise : OUI**

8. Inventaire des Fichiers Produits dans /kaggle/working

À l'issue de l'exécution, les artefacts suivants ont été créés et sont directement exploitables pour le déploiement n8n :

Nom du Fichier	Format / Taille	Description & Destination n8n
final_medical_reports_sample.json	JSON / ~25 KB	Comptes-rendus médicaux finaux complets avec XAI et sécurité (Bloc 7)
acr_guidelines_index.faiss	Binaire FAISS	Index vectoriel dense des recommandations cliniques ACR BI-RADS
acr_guidelines_chunks.csv	CSV	Textes et métadonnées des règles cliniques ACR indexées
rag_index.faiss	Binaire FAISS	Index vectoriel dense des 317 rapports cliniques patients BCMID
rag_chunks.csv	CSV	Passages textuels des rapports utilisés pour le Case-Based Reasoning
dossiers_fold0.jsonl	JSONL / 64 cas	Dossiers multimodaux combinant prédictions vision, fiches XAI et preuves
prompts_fold0.jsonl	JSONL / 188 prompts	Prompts conditionnés multimodaux prêts pour l'inférence LLM
reports_blind_clean.csv	CSV / 317 cas	Rapports d'origine anonymisés, caviardés et dé-doublonnés

9. Conclusion & Conformité au Projet

Le laboratoire de l'Agent RAG valide l'intégration réussie de l'intelligence artificielle générative dans un flux radiologique réaliste. En couplant la vision computationnelle (ResNet-18), l'ancrage normatif (guides ACR), l'explicabilité visuelle (Grad-CAM) et des garde-fous stricts contre les hallucinations, le système BCMID démontre sa capacité à générer des comptes-rendus médicaux décisionnels de haute fiabilité, prêts pour l'automatisation dans des workflows d'orchestration clinique tels que **n8n**.